

۱. تخصیص منابع آگاه از معناشناصی با DRL در HetNet های ۵G-V2X

مقاله اصلی:

[IEEE Xplore: Semantic-Aware Resource Allocation Based on Deep Reinforcement Learning for 5G-V2X HetNets](#)

خلاصه مفهومی و نوآوری کلیدی:

این مقاله یک پارادایم جدید «تخصیص منابع مبتنی بر معنا» در شبکه های V2X معرفی می کند. به جای برخورد یکسان با تمام داده ها، شاخص اهمیت معنایی SIS برای پیام ها مثلاً هشدار تصادف در مقابل بهروزرسانی ترافیک تعریف شده و در هسته تصمیم گیری الگوریتم DRL قرار می گیرد. هدف، اولویت دهی هوشمند به پیام های حیاتی برای بهبود قابلیت اطمینان و کاهش تأخیر در شبکه های ناهمگن 5G است.

جزئیات فنی و متداول زیری:

مدل سیستم: یک شبکه HetNet شامل ماکروسل، پیکو سل و ارتباطات مستقیم و سایل PC5 sidelink.

فرمول سازی MDP:

State: CQI [کلیه لینک ها، وضعیت بافر هر وسیله، SIS پیام های منتظر، موقعیت / سرعت و سایل، تاریخ چه تداخل]

Action: [تخصیص RB خاص به هر لینک، سطح توان ارسال، تنظیم Duty Cycle برای وسایل کم اهمیت]

Reward: $\sum \alpha_i \text{SIS} - \beta \text{مصرف توان}$

الگوریتم PPO: Proximal Policy Optimization به دلیل پایداری در فضای عمل پیوسته - گسسته.

معماری شبکه عصبی: Actor-Critic با لایه های FC و احتمالاً LSTM برای درک وابستگی زمانی.

دیناست و محیط شبیه سازی:

شبیه سازی ترافیک: SUMO برای حرکت واقع گرایانه وسایل.

وبسایت پروژه SUMO: <https://www.eclipse.org/sumo>

سناریوی نمونه: شبیه سازی شهر لوکزامبورگ <https://github.com/lcodeca/LuSTSceario>

شبیه سازی کانال و شبکه: Simu5G بر اساس OMNeT++ یا Python Gym Environment .

Simu5G: <https://github.com/unina-otns/simu5g>

تولید و برچسب گذاری پیام های V2X: پیام های CAM/DENM طبق استاندارد GPP3 با SIS دستی یا قاعده بندی شده مثلًا 10 CAM، DENM: ۷ اینمی.

ارزیابی و نتایج:

معیارهای کلیدی PRR: وزندار با SIS اصلی، تأخیر متوسط، توان مصرفی، کارایی طیف.

روش های مقایسه: Random, Greedy, DRL

نتایج گزارش شده فرضی از مقاله: بهبود ۳۵٪ در PRR پیام های حیاتی، افزایش ۱۵٪ کارایی طیف، کاهش ۲۰٪ تأخیر پیام های مهم.

کلیدواژه های پیش رفتہ:

Semantic-Aware Networking, Goal-Oriented Communication, PPO, Resource Allocation, 5G-V2X, HetNets.

۲. UniTSA: چارچوب یادگیری تقویتی جهان شمول برای کنترل چراغ های راهنمایی V2X

مقاله اصلی:

[IEEE Xplore: UniTSA: A Universal Reinforcement Learning Framework for V2X Traffic Signal Control](#)

خلاصه مفهومی و نوآوری کلیدی:

UniTSA با معرفی «ماتریس تقاطع Junction Matrix» به عنوان یک نمایش استاندارد از وضعیت ترافیک، مشکل وابستگی روش های RL به تقاطع خاص را حل می کند. این چارچوب یک عامل جهانی آموزش می دهد که می تواند بدون بازآموزی، در تقاطع های نادیده و جدید مستقر شود و عملکرد بهینه ارائه دهد یادگیری انتقال Zero-Shot.

جزئیات فنی و متداوله:

ماتریس تقاطع: یک تansور ۳ بعدی [ورودی ها، خطوط، ویژگی ها] شامل تعداد وسایل، سرعت، عابران، فاز فعلی و اطلاعات V2X.

فرمول سازی MDP:

State: ماتریس تقاطع تستیح شده.

Action: انتخاب فاز بعدی و مدت زمان آن.

Reward: ترکیبی منفی از طول صف، توقف ها و تأخیر عابران.

الگوریتم RL: Rainbow DQN به دلیل قدرت در فضاهای عمل گستته.

معماری: CNN برای درک ساختار مکانی ماتریس + لایه های FC.

دیتاست و محیط شبیه‌سازی:

شبیه‌ساز کنترل ترافیک: CityFlow کارایی بالا برای RL.

<https://github.com/cityflow-project/CityFlow> :GitHub CityFlow مخزن

دیتاست‌های ترافیک برای آموزش:

داده‌های واقعی: مجموعه داده‌های ترافیک شهری.

آرشیو داده‌های ترافیک PeMS pems.dot.ca.gov/Caltrans_PeMS

داده‌های مصنوعی: تولید شده توسط CityFlow با الگوهای متنوع.

ارزیابی: استفاده از داده‌های شهرهایی که در آموزش دیده نشده‌اند مثلاً برلین.

ارزیابی و نتایج:

معیارها: زمان سفر متوسط، زمان انتظار، نرخ گذر Throughput.

RL Fixed-Time, MaxPressure, IntelliLight **Baseline** خاص-تقاطع.

نتایج گزارش شده فرضی: عملکرد ۹۵٪ بهینه نسبت به عامل خاص-تقاطع، کاهش ۴۰-۳۰٪ زمان سفر، قابلیت استقرار فوری در هزاران تقاطع.

کلیدواژه‌های پیشرفتی:

Universal AI Agent, Junction Matrix, Transferable RL, Scalable Traffic Control, Meta-Learning for Control.

۳. محاسبات لبه خودرویی تقویت شده با RIS و هماهنگی چند عاملی

مقاله اصلی:

[IEEE Xplore: Reconfigurable Intelligent Surface Assisted VEC Based on Multi-Agent Reinforcement Learning]

خلاصه مفهومی و نوآوری کلیدی:

این پژوهش یک معماری سه لایه فیزیکی/RIS، محاسباتی/VEC، کنترل/DRL را ارائه می دهد که در آن یک سیستم چند عاملی DRL MADRL به طور هماهنگ سه تصمیم حیاتی را اتخاذ می کند: تخصیص منابع محاسباتی سرور، آفلوید کردن وظایف، و تنظیم فاز عناصر RIS. از الگوریتم ترکیبی MADDPG-BCD برای حل این مسئله بهینه سازی پیچیده و در همتایده استفاده می شود.

جزئیات فنی و متداوله:

مدلسازی چند عامله: هر وسیله و هر سرور لبه به عنوان یک عامل مستقل.

الگوریتم: MADDPG اصلاح شده احتمالاً با Attention یا Priority Replay برای آموزش همکاری بین عوامل.

بهینه سازی RIS: الگوریتم Block Coordinate Descent BCD برای تنظیم فاز عناصر RIS، با ثابت فرض کردن سیاست های MADDPG.

تابع پاداش سیستم: کاهش تأخیر کل و مصرف انرژی.

دیتابست و محیط شبیه سازی:

پروفایل وظایف محاسباتی:

برای مدل سازی وظایف ناهمگن <https://github.com/google/cluster-data>

مدلسازی کانال RIS: معادلات مبتنی بر هندسه برای مدل سازی مسیر دوگانه.

شبیه ساز شبکه و حرکت: ترکیب SUMO ترافیک با یک شبیه ساز شبکه مبتنی بر Python برای مدل سازی ارتباط و محاسبه.

ارزیابی و نتایج:

معیارها: تأخیر سرتاسری، نرخ موفقیت انجام وظیفه در مهلت زمانی، انرژی مصرفی.

ها: سیستم بدون RIS، روش های حریصانه محلی، الگوریتم های بهینه سازی کلاسیک Baseline.

نتایج گزارش شده فرضی: کاهش ۴۵٪ تأخیر متوسط با RIS، افزایش ۶۰٪ نرخ موفقیت وظایف.

کلیدواژه های پیشرفت:

Reconfigurable Intelligent Surfaces RIS, Vehicular Edge Computing VEC, MADDPG, Multi-Agent DRL, Joint Communication and Computation Optimization.

۴. کمی‌سازی هوشمند گرادیان با DRL توزیع شده برای یادگیری فدرال در VEC

مقاله اصلی:

[IEEE Xplore: Distributed Deep Reinforcement Learning-Based Gradient Quantization for Federated Learning Enabled Vehicle Edge Computing]

خلاصه مفهومی و نوآوری کلیدی:

این مقاله یک روش کمی‌سازی تطبیقی و مبتنی بر DRL برای کاهش بار ارتباطی در یادگیری فدرال FL معرفی می‌کند. هر وسیله دارای یک عامل DRL محلی است که بر اساس وضعیت کanal، باتری و اهمیت داده‌هایش، سطح دقت کمی‌سازی تعداد بیت گرادیان‌های محلی را به طور پویا انتخاب می‌کند. این کار موازنۀ بهینه‌ای بین دقت مدل و کارایی ارتباط ایجاد می‌کند.

جزئیات فنی و متداول‌تری:

فرمول‌سازی MDP محلی برای هر وسیله:

State: [کیفیت کanal، سطح باتری، ناهمگنی داده‌های محلی]

Action: انتخاب سطح کمی‌سازی مثلاً ۲، ۴، ۸ بیت.

Reward: زمان انتقال + انرژی - خطای کمی‌سازی.

آموزش توزیع شده: هر عامل به طور مستقل و بدون اشتراک‌گذاری داده‌های حساس آموزش می‌بیند.

یکپارچه‌سازی با چرخه FL: عامل در هر دور، سطح بیت را انتخاب و گرادیان را کمی می‌کند.

دیتاست و محیط شبیه‌سازی:

کار FL در VEC:

تشخیص عابر پیاده: /<https://www.cityscapes-dataset.com/>

پیش‌بینی ترافیک: /<https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>

ناهمگنی داده: تقسیم غیریکنواخت دیتاست بین وسایل مثلاً بر اساس منطقه جغرافیایی.

ارزیابی و نتایج:

معیارها: دقت نهایی مدل جهانی، سرعت همگرایی، کل ترافیک ارتباطی، انرژی مصرفی.

Baseline‌ها: کمی‌سازی ثابت ۴ بیت، AdaQuant ۱ بیت، SignSGD.

نتایج گزارش شده فرضی: دستیابی به دقت مشابه FL اصلی با ۷۰٪ کاهش ترافیک، همگرایی ۲۰٪ سریع‌تر از کمی‌سازی ثابت.

کلیدواژه‌های پیشرفته:

Adaptive Gradient Quantization, Distributed DRL, Communication-Efficient Federated Learning, Vehicular Edge Computing, Heterogeneous Data.

۵. تخصیص منابع شناختی برای V2X با ادغام GNN و DRL

مقاله اصلی:

[IEEE Xplore: Graph Neural Networks and Deep Reinforcement Learning-Based Resource Allocation for V2X Communications]

خلاصه مفهومی و نوآوری کلیدی:

این مقاله شبکه V2X را به عنوان یک گراف هتروژن مدل می‌کند و با ادغام شبکه‌های عصبی گراف GNN و یادگیری تقویتی عمیق DRL، یک چارچوب تخصیص منابع شناختی و مبتنی بر رابطه ارائه می‌دهد. GNN با جمع‌آوری اطلاعات از همسایگان در گراف، نمایه‌های تعییشده غنی برای هر نهاد ایجاد می‌کند که حاوی اطلاعات زمینه‌ای شبکه مانند الگوی تداخل است. سپس یک عامل DRL از این نمایه‌ها برای تخصیص بهینه منابع طیفی استفاده می‌کند.

جزئیات فنی و متداول‌ری:

مدل‌سازی گراف: گره‌ها = وسایل و زیرساخت؛ یال‌ها = لینک‌های مطلوب و تداخل.

الگوریتم GNN: GraphSAGE برای استخراج ویژگی‌های غنی از گراف با مکانیزم Update Aggregate و الگوریتم DRL: DQN که نمایه‌های خروجی GNN را به عنوان state دریافت می‌کند.

تابع پاداش: افزایش نرخ داده موفق و کاهش تداخلات اندازه‌گیری شده.

دیتاست و محیط شبیه‌سازی:

شبیه‌ساز: پلتفرم سفارشی Python با استفاده از کتابخانه‌های:

برای GNN: <https://www.dgl.ai/> یا <https://pytorch-geometric.readthedocs.io/>

برای DRL: <https://docs.ray.io/en/latest/rllib/index.html>

سناریوهای تراکم: خیابان‌ها و تقاطع‌های با تراکم متغیر وسایل ۵۰ تا ۲۰۰ وسیله/کیلومتر مربع.

مدل کanal: استاندارد GPP^۳ برای محیط‌های شهری.

ارزیابی و نتایج:

معیارها: نرخ تحویل بسته PDR برای V2V، نرخ داده برای V2I، تأخیر، کارایی طیفی.

نتایج: تخصیص تصادفی، حریصانه مبتنی بر CQI، DRL خالص بدون GNN.

نتایج گزارش شده فرضی: بیبود ۲۵٪ در PDR لینک‌های V2V در تراکم بالا، قابلیت تعمیم پذیری به توپولوژی‌های جدید.

کلیدواژه‌های پیشرفتی:

Graph Neural Networks GNN, Geometric Deep Learning, Relational Reasoning, C-V2X, DQN, Interference-Aware Scheduling.